Probabilidad de bloqueo en colas M/M/1/K y M/M/c/K con espacio limitado

Cael Alejandro Soto Castillo[1]

[1]Facultad de Ingeniería, Universidad Nacional de Loja, Loja, Ecuador

cael.soto@unl.edu.ec

***Resumen*—Cuando una cola tiene espacio limitado y ya está llena, los clientes que llegan no pueden entrar y se pierden, la probabilidad de que esto ocurra se llama probabilidad de bloqueo. Este ensayo explica cómo se calcula en las colas M/M/1/K (un servidor) y M/M/c/K (varios servidores) y revisa cómo la usan seis trabajos de redes y telecomunicaciones. El objetivo es entender qué cambia entre un modelo y otro y mostrarlo con un ejemplo mío propio. Se buscó en Scopus e IEEE Xplore con cuatro cadenas de búsqueda y se escogieron seis artículos con modelos analíticos, aplicaciones y simulaciones. Algo interesante fue que los trabajos coinciden en que el bloqueo crece con la carga y baja con más recursos, y sus diferencias vienen de los supuestos de cada modelo y no de contradicciones. En el ejemplo, con 4 solicitudes por segundo, servidores que atienden 3 por segundo y espacio para 5, pasar de uno a dos servidores baja el bloqueo de 30.4 % a 5.9 %, mientras que ampliar la cola con un solo servidor casi no lo mejora y aumenta la espera. Se concluye que, con el sistema sobrecargado, conviene más agregar servidores que espacio de espera.**

***Palabras clave*—bloqueo; capacidad finita; Erlang B; M/M/1/K; M/M/c/K; teoría de colas**

I. Introducción

Casi en cualquier servicio se atiende a clientes con un espacio de espera ya puesto, por ejemplo, un router tiene memoria para guardar cierta cantidad de paquetes, una central telefónica tiene un número fijo de líneas y un servidor atiende una máxima cantidad de solicitudes al mismo tiempo. En cada caso si todo está ocupado el que llega no entra y se pierde. Aquí entra la teoría de colas, pues estudia esta situación con colas de capacidad finita y su medida principal es la probabilidad de bloqueo: la proporción de clientes que llega y no puede entrar [1]. Calcularla sirve para decidir cuánto espacio o cuántos servidores hacen falta, porque si el bloqueo es muy alto se pierde servicio y si se sobredimensiona se gasta de más.

Los modelos más usados para esto son M/M/1/K con un servidor, y M/M/c/K con c servidores trabajando en paralelo. Estos se aplican en redes WiFi [2], en los conmutadores de redes definidas por software [3] (SDN: donde un controlador central decide cómo circula el tráfico), en redes ópticas [4], en telefonía [5], en sistemas donde los clientes reintentan [6] y en los controladores de una red [7]. El objetivo de este ensayo es explicar cómo se calcula la probabilidad de bloqueo en estos dos modelos, comparar cómo la usan seis trabajos y mostrar con un ejemplo numérico propio qué cambia al pasar de uno a dos servidores. Este ensayo se estructura de la siguiente manera: la sección II explica el tema y la metodología de búsqueda, la sección III compara los trabajos y desarrolla el ejemplo, y la sección IV presenta las conclusiones.

II. Marco teórico y metodología

II-A. *Espacio limitado y probabilidad de bloqueo*

En una cola los clientes llegan, esperan si todos los servidores están ocupados y salen cuando los atienden. Si la cola fuera infinita nadie se perdería, pero la espera podría crecer sin límite. En la práctica el espacio es limitado: se define K como el máximo de clientes que puede haber dentro del sistema al mismo tiempo, contando los que están siendo atendidos y los que esperan [1]. Cuando se llega a K, el siguiente que llega se bloquea y se pierde. Es ese límite lo que puede ser la memoria de un router, los canales de una celda o la cantidad de solicitudes que acepta un servidor. Otra variable importante aquí es la probabilidad de bloqueo (P_K) que es la probabilidad de que el sistema esté lleno cuando llega un cliente, y si las llegadas son aleatorias coincide con el porcentaje de clientes que se pierde [1]. Con ella se calcula la tasa efectiva de llegada: $\lambda_{\text{ef}} = \lambda(1 - P_K)$, que es el ritmo al que los clientes sí entran. Con λ_{ef} y la ley de Little, $L = \lambda_{\text{ef}} W$, se obtiene el tiempo medio W que un cliente pasa en el sistema a partir del número medio de clientes L [1]. También además, una consecuencia del límite de espacio es que la carga puede superar la capacidad de atención sin que la cola crezca para siempre, porque lo que sobra se bloquea.

II-B. *Modelos M/M/1/K y M/M/c/K*

Son dos modelos que suponen que los clientes llegan al azar y de forma independiente (llegadas de Poisson) y que el tiempo de atención varía de un cliente a otro, con muchos tiempos cortos y pocos largos (distribución exponencial). y como ya lo he dicho en varias partes anteriores, la diferencia es que M/M/1/K tiene un servidor y M/M/c/K tiene c servidores que toman clientes de una misma cola. La Tabla I resume los símbolos que se usan.

Tabla I
SÍMBOLOS USADOS EN EL ENSAYO

Símbolo	Significado
λ	Tasa de llegada: clientes que llegan por unidad de tiempo
μ	Tasa de servicio: clientes que un servidor atiende por unidad de tiempo
c	Número de servidores que atienden en paralelo
K	Capacidad del sistema: máximo de clientes dentro (en servicio más en espera), con $K \geq c$
$a = \lambda/\mu$	Carga ofrecida, medida en Erlangs
$\rho = a/c$	Utilización por servidor
P_K	Probabilidad de bloqueo

Para M/M/1/K con $\rho = \lambda/\mu$, la probabilidad de bloqueo es [2], [3]:

$$P_K = \frac{(1-\rho)\,\rho^K}{1-\rho^{K+1}} \tag{1}$$

Si ρ es igual a 1 la fórmula no se puede evaluar directamente y el resultado es $P_K = 1/(K+1)$. Otro caso especial es K igual a c, pues no hay lugar de espera y todo cliente que encuentra los servidores ocupados se pierde. Este sistema se conoce como Erlang B y su bloqueo es [4], [5]:

$$B(c,a) = \frac{a^c/c!}{\sum_{k=0}^{c} a^k/k!} \tag{2}$$

Para M/M/c/K con lugares de espera, la fórmula estándar es [1]:

$$P_0 = \left[\sum_{n=0}^{c-1} \frac{a^n}{n!} + \frac{a^c}{c!}\sum_{j=0}^{K-c} \rho^j\right]^{-1} \tag{3}$$

$$P_K = \frac{a^c}{c!}\,\rho^{K-c}\,P_0 \tag{4}$$

Aquí P_0 es la probabilidad de que el sistema esté vacío. Las fórmulas (3) y (4) se reducen a (1) cuando c = 1 y a (2) cuando $K = c$, lo que sirve como comprobación. También la suma de potencias de ρ vale $(1-\rho^{K-c+1})/(1-\rho)$ si $\rho \neq 1$ y $K-c+1$ si $\rho = 1$.

II-C. Estrategia de búsqueda

La búsqueda se hizo en Scopus e IEEE Xplore con cuatro cadenas: “M/M/c/K” AND “blocking probability”; “finite buffer” AND “blocking probability” AND network; Erlang B blocking probability; y “blocking probability” AND “discrete event simulation”. Se prefirieron publicaciones de 2015 en adelante, de tipo artículo de revista o de conferencia. Dos de los trabajos finales son anteriores (2013 y 2004) y se aceptaron porque aportan algo que los recientes no, y es que Kosek-Szott [2] es la referencia directa de M/M/1/K aplicado a WiFi y Kaheel et al. [4] compara un modelo de bloqueo sin cola con simulaciones. El criterio de selección fue que el trabajo trate la probabilidad de bloqueo en un sistema de capacidad finita con modelo analítico, aplicación o simulación. De ahí quedaron seis artículos: dos con M/M/1/K ([2], [3]), dos sin lugares de espera ([4], [5]) y dos con M/M/c/K y clientes que se comportan de forma más realista ([6], [7]). También para desarrollar la fórmula estándar de M/M/c/K se tomó del libro de texto [1].

III. DESARROLLO Y ANÁLISIS

Los seis trabajos usan la probabilidad de bloqueo para problemas distintos, y la Tabla II los resume. Kosek-Szott [2] modela cada dispositivo de una red WiFi como una cola M/M/1/K y calcula cuántos datos se pierden cuando esa cola se llena. Sus resultados se parecen a los de las simulaciones, y con mucho tráfico y más dispositivos el bloqueo supera 0.6. Kim et al. [3] hacen lo mismo con cada conmutador (*switch*) de una red SDN y usan el modelo para estimar pérdida y retardo, de modo que pueden probar rutas sin tocar la red real. Kaheel et al. [4] estudian un enlace óptico con varios canales y sin lugar de espera, es decir, un caso tipo Erlang B, y su modelo queda cerca de las simulaciones. Cruz-Pérez et al. [5] parten también de Erlang B y proponen una variante para ajustar el bloqueo con más precisión en un sistema de telefonía celular. Zidani et al. [6] estudian una cola M/M/C/K donde los clientes rechazados pueden reintentar más tarde y algunos abandonan. Y por último, Uma Maheswari y Vasudevan [7] modelan los controladores de una red SDN como M/M/c/K con clientes que se cansan de esperar, y calculan el costo total del sistema con tres controladores, al subir la velocidad de atención de 50 000 a 70 000 flujos por segundo, la pérdida máxima baja de 0.15 a 0.05.

Tabla II
RESUMEN DE LOS TRABAJOS REVISADOS

Trabajo	Modelo	Qué aporta al tema
Kosek-Szott [2]	M/M/1/K	WiFi: pérdida de datos cuando se llena la cola de cada dispositivo
Kim et al. [3]	M/M/1/K	Conmutadores SDN: pérdida y retardo sin usar la red real
Kaheel et al. [4]	Sin espera (Erlang B)	Redes ópticas: bloqueo en un enlace con varios canales, comparado con simulación
Cruz-Pérez et al. [5]	Erlang B	Telefonía celular: variante para ajustar mejor el bloqueo
Zidani et al. [6]	M/M/C/K	Clientes que reintentan o abandonan; solución numérica
Uma Maheswari y Vasudevan [7]	M/M/c/K	Controladores SDN: clientes que abandonan y modelo de costos

Los trabajos coinciden en lo básico: el bloqueo sube cuando aumenta la carga y baja cuando hay más recursos, y los modelos matemáticos se pueden comparar con simulaciones. Entonces no se contradicen, lo que cambia entre uno y otro son los supuestos del modelo: si hay uno o varios servidores ([2] y [3] frente a [4]–[7]), si hay lugares de espera ([4] y [5] no los tienen) y si se agregan comportamientos como reintentar

o abandonar ([6], [7]). Estos últimos hacen que las fórmulas ya no sean las estándar, y por eso, para M/M/c/K, se usó la del libro [1] en lugar de las de [6] y [7].

Para ver el efecto con valores propios se tomó un sistema donde llegan $\lambda = 4$ solicitudes por segundo, cada servidor atiende $\mu = 3$ por segundo y caben $K = 5$ solicitudes. Con un servidor, $\rho = 4/3$ y la fórmula (1) da:

$$P_K = \frac{\left(1 - \frac{4}{3}\right)\left(\frac{4}{3}\right)^5}{1 - \left(\frac{4}{3}\right)^6} = 0.3041,$$

es decir, casi una de cada tres solicitudes se pierde. Con dos servidores, $a = 4/3$ y $\rho = 2/3$, y las fórmulas (3) y (4) dan:

$$P_0 = \left[1 + \frac{4}{3} + \frac{8}{9}\left(1 + \frac{2}{3} + \frac{4}{9} + \frac{8}{27}\right)\right]^{-1} = 0.2236,$$

$$P_K = \frac{8}{9}\left(\frac{2}{3}\right)^3 P_0 = 0.0589.$$

El bloqueo baja de 30.4 % a 5.9 %. Como entran más solicitudes, λ_{ef} sube de 2.78 a 3.76 por segundo, y con la ley de Little el tiempo medio en el sistema baja de 1.19 s a 0.46 s.

La Tabla III agrega $K = 10$ y el caso sin espera ($K = 2$, Erlang B). Con un servidor, duplicar K casi no ayuda, pues el bloqueo pasa de 0.304 a 0.261 y el tiempo en el sistema se duplica de 1.19 s a 2.53 s. Esto ocurre porque $\rho > 1$, lo que significa que llega más trabajo del que el servidor puede atender y la cola termina llena casi siempre, así que el bloqueo no baja de 0.25 (el valor $1 - 1/\rho$) por grande que sea K. Por otra parte, con dos servidores $\rho < 1$, y cada lugar extra de espera sí reduce mucho el bloqueo: 0.0589 con $K = 5$ y 0.0070 con $K = 10$, con tiempos de 0.46 s y 0.57 s. Un solo servidor del doble de velocidad ($\mu = 6$) da con $K = 5$ un bloqueo de 0.048 y un tiempo de 0.37 s, algo mejor que los dos servidores lentos. Esto concuerda con lo que muestran los trabajos: que pesa más tener capacidad de atención suficiente que alargar la cola, y una cola larga se paga en tiempo de espera, algo que Uma Maheswari y Vasudevan [7] incluyen en su modelo de costos.

Tabla III
RESULTADOS DEL EJEMPLO PROPIO ($\lambda = 4$ SOLICITUDES/S, $\mu = 3$ SOLICITUDES/S POR SERVIDOR)

Modelo	K	P_K	λ_{ef}	L	W (s)
M/M/1/K	5	0.3041	2.7835	3.2991	1.1852
M/M/2/K	5	0.0589	3.7645	1.7406	0.4624
M/M/2/2 (Erlang B)	2	0.2759	2.8966	0.9655	0.3333
M/M/1/K	10	0.2610	2.9559	7.4851	2.5322
M/M/2/K	10	0.0070	3.9719	2.2509	0.5667

IV. CONCLUSIONES

El objetivo era explicar cómo se calcula la probabilidad de bloqueo en colas M/M/1/K y M/M/c/K, comparar cómo la usan seis trabajos y ver qué cambia al pasar de uno a dos servidores. En M/M/1/K el bloqueo depende de la carga ρ y de K, y en M/M/c/K también del número de servidores; Erlang B es el caso en que no hay lugares de espera. Los trabajos revisados aplican estas ideas en redes WiFi, redes SDN, redes ópticas y telefonía, y las diferencias entre ellos vienen de los supuestos de cada modelo. En el ejemplo, con $\lambda = 4$, $\mu = 3$ y $K = 5$, pasar a dos servidores reduce el bloqueo de 30.4 % a 5.9 %, mientras que alargar la cola con un solo servidor apenas lo mueve y aumenta la espera.

La comparación tiene límites. La comparación entre los trabajos es cualitativa, porque cada uno trabaja con un sistema y parámetros distintos y sus resultados no se pueden contrastar número a número. Además, el ejemplo usa un solo juego de parámetros resuelto con fórmulas, así que sus conclusiones valen para ese caso y no para cualquier sistema. Como trabajo futuro se propone simular por eventos discretos el mismo ejemplo para comprobar los valores de la Tabla III, probar tiempos de atención que no sean exponenciales y agregar abandono de clientes al ejemplo para compararlo con [6] y [7] con los mismos parámetros.

DECLARACIÓN DE USO DE INTELIGENCIA ARTIFICIAL

Utilicé la herramienta de IA como apoyo para extraer la información relevante en base al tema de los artículos seleccionados y no obtener información poco relevante de estos. Yo me encargué de buscar y descargar los artículos y los cargué en NotebookLM.

PROMT1: “Usa solo las fuentes activas. No inventes datos, fórmulas ni referencias. Si algo no está en las fuentes, escribe [NO EN FUENTES]. Dame, por fuente, el modelo que usa, qué calcula, el método y los resultados principales. Enfoca tus respuestas en base al siguiente tema: Probabilidad de bloqueo en colas M/M/1/K y M/M/c/K con espacio limitado”

REFERENCIAS

[1] D. Gross, J. F. Shortle, J. M. Thompson, and C. M. Harris, *Fundamentals of Queueing Theory*, 4th ed. Hoboken, NJ, USA: Wiley, 2008.

[2] K. Kosek-Szott, “Throughput, delay, and frame loss probability analysis of IEEE 802.11 DCF with M/M/1/K queues,” in *Proc. IEEE 24th Int. Symp. Pers., Indoor Mobile Radio Commun. (PIMRC)*, London, U.K., Sep. 2013, pp. 2234–2238, doi: 10.1109/PIMRC.2013.6666515.

[3] G. Kim, Y. Kim, and H. Lim, “Deep reinforcement learning-based routing on software-defined networks,” *IEEE Access*, vol. 10, Feb. 2022, doi: 10.1109/ACCESS.2022.3151081.

[4] A. Kaheel, H. Alnuweiri, and F. Gebali, “Analytical evaluation of blocking probability in optical burst switching networks,” in *Proc. IEEE Int. Conf. Commun. (ICC)*, Paris, France, Jun. 2004, vol. 3, pp. 1548–1553.

[5] F. A. Cruz-Pérez, S. L. Castellanos-López, and G. Hernández-Valdez, “Queueing systems with fractional number of servers: Analysis and practical implementation of the Erlang-B traffic model,” *IEEE Access*, vol. 12, pp. 166268–166280, Nov. 2024, doi: 10.1109/ACCESS.2024.3491637.

[6] N. Zidani, P. Spiteri, and N. Djellab, “Numerical solution for the performance characteristics of the M/M/C/K retrial queue with negative customers and exponential abandonments by using value extrapolation method,” *RAIRO Oper. Res.*, vol. 53, no. 3, pp. 767–786, Jul.–Sep. 2019, doi: 10.1051/ro/2017059.

[7] G. Uma Maheswari and K. Vasudevan, “Developing a cost model for a multi-controller software-defined network using M/M/c/K queue with retention of reneged flows,” in *Proc. 1st Int. Conf. Comput. Electron. Wireless Commun. (ICCWC)*, Lecture Notes in Networks and Systems, vol. 329. Singapore: Springer, 2022, pp. 271–280, doi: 10.1007/978-981-16-6246-1_23.